



Administración del Sistema

Dirigido a: **Administrador del Sistema (System Admin)**

Este manual está dirigido al **Administrador del Sistema (System Admin)** de la plataforma agéntica multi-tenant. Reúne las pantallas de administración global que NO pertenecen a un tenant concreto: gestión de usuarios y su acceso a tenants, catálogo de proveedores LLM (ADR 0021/0028), administración del Ollama del stack, catálogo de precios de modelos, valores por defecto de plataforma y las herramientas de copia de seguridad (programación, destinos remotos y restauración).

Todas estas pantallas requieren rol System Admin. El backend protege cada endpoint con `require_system_admin` sobre una sesión con privilegios globales (BYPASSRLS) y, en la interfaz, un RoleGuard oculta la superficie a otros roles. Si accedes sin ese rol, verás un aviso de sección exclusiva o, en algunas pantallas (programación de backups, destinos), una vista de solo lectura. Las credenciales y secretos nunca se muestran ni se guardan en base de datos: viven en Vault o en el secret seam de los workers.

La pantalla de Estadísticas por tenant se incluye aquí por contexto operativo, aunque su acceso es de **tenant_admin** (no System Admin) y muestra únicamente los datos del tenant activo.

Contenido

- | | |
|----|-----------------------------------|
| 01 | Usuarios de la plataforma |
| 02 | Proveedores LLM |
| 03 | Ollama y Embeddings |
| 04 | Modelos y Precios |
| 05 | Valores por defecto de plataforma |
| 06 | Programación de backups |
| 07 | Destinos remotos de backup |
| 08 | Restaurar desde backup |
| 09 | Estadísticas del tenant |

1 Usuarios de la plataforma

Esta pantalla gestiona los **usuarios globales** de la plataforma. Los usuarios no pertenecen a un tenant: el acceso a cada tenant lo otorgan exclusivamente las *membership* (usuario + tenant + rol) que asigna el System Admin desde aquí (ADR 0047, deny-by-default: sin membership activa el usuario no entra a ningún tenant).

- Una **barra de búsqueda** filtra los usuarios por email o nombre.
- La **tabla** muestra por cada usuario: nombre, email, tipo (**System Admin** o **Usuario**) y estado (activo/inactivo).
- El botón **«Gestionar tenants»** abre un diálogo para administrar las membership de ese usuario.

En el diálogo de membership puedes: ver los tenants a los que el usuario tiene acceso con su rol y estado; cambiar el rol de una membership (Tenant Admin, Tenant User o System Operator); activar o desactivar una membership pulsando su badge de estado; revocar el acceso con el icono de papelera; y, en el formulario inferior **«Asignar acceso a un tenant»**, elegir un tenant disponible y un rol y pulsar **«Asignar»**.

Usuarios
Usuarios globales de la plataforma. El acceso a cada tenant lo dan las membership (usuario+tenant + rol) que asigna el System Admin (ADR 0047).

Q Buscar por email o nombre...

USUARIO	EMAIL	TIPO	ESTADO	ACCESO A TENANTS
Root	root@example.com	System Admin	activo	Gestionar tenants
Sysadmin 06 8	sysadmin-06-8@example.com	System Admin	activo	Gestionar tenants
Demo Manuales Admin	demo@example.com	System Admin	activo	Gestionar tenants

Figura 09.1 — Usuarios de la plataforma

2 Proveedores LLM

Catálogo global de proveedores LLM (ADR 0021/0028). Solo se admiten los cuatro caminos cerrados: **Claude Agent SDK**, **GitHub Copilot**, **Azure AI Foundry (APIM)** y **Ollama**. La configuración es global de plataforma y las credenciales se guardan únicamente en Vault; la interfaz nunca muestra el secreto, solo si la credencial está «configurada».

La **tabla** lista cada proveedor con su tipo, slug, nombre, endpoint, estado de la credencial, estado activo/inactivo y el resultado de la última prueba de conexión. Acciones por fila:

- **Probar conexión** (icono de enchufe): comprueba el proveedor y muestra OK o un error clasificado.
- **Sincronizar modelos** (icono de refrescar): descubre los modelos que sirve el proveedor y los vuelca en su catálogo para los selectores de modelo.
- **Autorizar con GitHub** (solo Copilot): abre el diálogo de Device Flow.
- **Editar y Eliminar**; el badge de estado activa/desactiva el proveedor sin abrir el diálogo.

El botón «**Nuevo proveedor**» abre el formulario de alta: tipo, nombre, slug único (minúsculas, números y guiones), endpoint (obligatorio para Azure Foundry y Ollama) y el campo de credencial que cambia según el tipo (token OAuth, API key de APIM o bearer token de Ollama). Al editar, dejar el campo de credencial vacío conserva el secreto actual; escribir un valor lo rota. En el diálogo de **GitHub Copilot** se inicia el Device Flow, que muestra un código de usuario y un enlace de verificación; tras autorizar en GitHub, el token se acuña y se guarda solo en Vault.

Proveedores LLM
Catálogo global de proveedores LLM (ADR 0021/0028). Configuración platform-global, solo System Admin. Las credenciales se guardan únicamente en Vault.

TIPO	SLUG	NOMBRE	ENDPOINT	CREDENCIAL	ESTADO	CONEXIÓN	ACCIONES
Ollama	ollama-local	Ollama local	http://localhost:11434/v1	sin credencial	activo	—	🔌 ↺ ✎ 🗑️
Ollama	ollama-cloud	Ollama cloud	https://ollama.com/v1	🔑 configurada	activo	—	🔌 ↺ ✎ 🗑️

Figura 09.2 — Proveedores LLM

3 Ollama y Embeddings

Administra el Ollama del stack (ADR 0056). La pantalla tiene dos secciones.

Embeddings (solo lectura/descubrimiento): muestra el modelo de embeddings *activo*, la dimensión requerida (768), si Ollama es accesible, qué modelos instalados son embedders válidos y compatibles, y una lista de modelos recomendados. El modelo activo se fija por variable de entorno en la instalación; cambiarlo con bases de conocimiento existentes es un trabajo de re-indexado aparte. El botón **«Actualizar»** recarga los datos.

Modelos Ollama: lista los modelos instalados con su tamaño. Para **descargar (pull)** un modelo escribe su nombre (p. ej. `nomic-embed-text`) y pulsa **«Pull»**; para borrarlo usa el icono de papelera de su fila. Si Ollama no está accesible se muestra un aviso para revisar que el servicio del stack está levantado. Toda la pantalla es exclusiva del System Admin.

The screenshot shows the 'Ollama & Embeddings' management page in the Agentic Platform. The interface is in Spanish and includes a sidebar with navigation options like 'TRABAJO', 'RECURSOS', 'CONFIGURACIÓN DEL TENANT', 'PLATAFORMA', and 'AYUDA'. The main content area is divided into two sections: 'Embeddings' and 'Modelos Ollama'. The 'Embeddings' section displays the active model ('nomic-embed-text'), required dimension (768), and a status 'Ollama accesible'. It also shows a table of installed embedders and a list of recommended models. The 'Modelos Ollama' section provides a form to download (pull) a model and a table of installed models with their sizes and delete actions.

EMBEDDER INSTALADO	DIM	COMPATIBLE (768)	ACTIVO
nomic-embed-text:latest	768	si	★

MODELO	TAMAÑO	ACCIONES
nomic-embed-text:latest	261.6 MB	[Icono de papelera]
llama3.2:1b	1.2 GB	[Icono de papelera]

Figura 09.3 — Ollama y Embeddings

Modelos y Precios

Catálogo global de precios de modelos en **USD canónico**, con soporte de *prompt caching* (precio de lectura de caché). La lectura del catálogo está abierta a cualquier usuario autenticado; la edición (crear, editar, superseder, sincronizar) es solo System Admin.

En la parte superior, un aviso indica el alcance del sincronizador: solo importa las familias de los proveedores LLM *activos*; si no hay ninguno activo, se invita a activar uno en Proveedores LLM. El bloque de **filtros** permite acotar por familia (provider), modelo, modalidad, proveedor de plataforma asociado y el toggle **«Solo vigentes»**; pulsa **«Filtrar»** o **«Limpiar»**.

La **tabla** muestra familia, modelo, modalidad, proveedor asociado, precios de input/output/caché, unidad, fuente y vigencia. Acciones por fila: **Histórico** (ícono de reloj) abre un diálogo con la línea temporal de precios y una gráfica; **Editar** y **Superseder** (cerrar el periodo vigente) solo para System Admin. El botón **«Nuevo precio»** abre el formulario de alta. El botón **«Sincronizar precios»** abre un diálogo de previsualización (dry-run) con el diff de cambios (nuevos, actualizados, subidas >10%, discontinuados); nada se escribe hasta confirmar, y una subida superior al 10% exige marcar una casilla de confirmación explícita antes de aplicar.

AGENTIC PLATFORM

TRABAJO

RECURSOS

CONFIGURACIÓN DEL TENANT

PLATAFORMA

Usuarios

Proveedores LLM

Ollama & Embeddings

Valores por defecto

Modelos & Precios

Auth/SSO

Backups

Destinos backup

Restaurar backup

AYUDA

Demo Manuales

SYSTEM_ADMIN

ES

EN

D

Demo Manuales Admin

demo@example.com

Modelos & Precios

Catálogo global de precios de modelos (USD canónico, con soporte de prompt caching). Lectura abierta; edición solo System Admin.

Sincronizar precios

Nuevo precio

Sincronizando solo: ollama (familias de los proveedores LLM activos — ADR 0028). El resto del feed se omite.

Familia (provider)

Modelo

Modalidad

Proveedor (plataforma)

anthropic

claude-sonnet-4-5

Todas

Todos

Solo vigentes

Filtrar

Limpiar

Familia	Modelo	Modalidad	Proveedor	Input	Output	Cache	Unidad	Fuente	Vigencia	Acciones	
ollama	ollama/codegeex4	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/codegemma	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/codellama	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/deepseek-coder-v2-base	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/deepseek-coder-v2-instruct	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/deepseek-coder-v2-lite-base	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/deepseek-coder-v2-lite-instruct	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/deepseek-v3.1:671b-cloud	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/gpt-oss:120b-cloud	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/gpt-oss:20b-cloud	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/interlm2_5-20b-chat	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama2	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama2-uncensored	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama2:13b	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama2:70b	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama2:7b	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama3	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama3.1	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama3:70b	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/llama3:8b	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/mistral	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/mistral-7B-Instruct-v0.1	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/mistral-7B-Instruct-v0.2	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/mistral-large-instruct-2407	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/mixtral-8x22B-Instruct-v0.1	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/mixtral-8x7B-Instruct-v0.1	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/orca-mini	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/qwen3-coder:480b-cloud	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		
ollama	ollama/vicuna	text	sin asociar	\$0	\$0	—	por 1M tokens	litellm	vigente		

Figura 09.4 — Modelos y Precios

Valores por defecto de plataforma

Edita los ajustes globales de la plataforma que no tienen página propia (modelo por defecto de agentes según ADR 0055, límites de ejecución, RAG, mantenimiento, etc.). Los ajustes se agrupan en **tarjetas por categoría** guiadas por el registro del backend, sin valores cableados en la interfaz.

Cada ajuste muestra su etiqueta, una descripción y su clave técnica. El control depende del tipo: una casilla para los booleanos (Activado/Desactivado), un campo numérico con mínimo y máximo para enteros, un campo de texto para decimales, y un control de **configuración de modelo** (proveedor por *kind*, modelo y temperatura) para el modelo por defecto de agentes. Cada control tiene su propio botón «**Guardar**», que valida el valor por tipo y lo persiste; al elegir un proveedor, el desplegable de modelo se rellena con los modelos sincronizados de ese proveedor (o puedes escribir el nombre si no hay sincronizados). Solo System Admin.

AGENTIC PLATFORM

TRABAJO

RECURSOS

CONFIGURACIÓN DEL TENANT

Guardrails

Validación humana

Notificaciones

Calidad (Evals)

Estadísticas

Marketplace

Settings

PLATAFORMA

Usuarios

Proveedores LLM

Ollama & Embeddings

Valores por defecto

Modelos y Precios

Auth/SSO

Backups

Destinos backup

Demo Manuales

SYSTEM_ADMIN

ES

EN

D

Demo Manuales Admin

demo@example.com

Valores por defecto de plataforma

Ajustes globales de la plataforma sin página propia (modelo por defecto de agentes, límites de ejecución, RAG, mantenimiento...). Solo System Admin.

Modelos

Modelo que heredan los agentes que no fijan uno propio.

Modelo por defecto de agentes

Proveedor (kind) + modelo + temperatura que heredan los agentes sin modelo propio (ADR 0055). El dispatch resuelve el proveedor más nuevo ACTIVO de ese kind.
model.default_config

Proveedor (kind)

ollama

Modelo

qwen3-coder:480b

Temperatura

0.2

Guardar

Ejecución

Límites y reintentos de las ejecuciones de agentes.

Reintentos máximos de revisión

Cuántas veces un agente puede reworkear su salida tras un reject.
max_review_retries

3

Guardar

Límite de tiempo soft (s)

SoftTimeLimit por ejecución; el agente puede capturarlo.
execution_soft_time_limit_s

1800

Guardar

Límite de tiempo hard (s)

HardTimeLimit por ejecución (SIGKILL). Debe ser > soft.
execution_hard_time_limit_s

2100

Guardar

Planes

Política de aprobación de planes.

Umbral de doble firma

Coste estimado (IA) por encima del cual un plan exige una SEGUNDA firma. 0 = siempre basta una firma.
plan_approval_double_signature_threshold

0

Guardar

RAG

Recuperación aumentada (búsqueda en KBs).

Reranker del RAG

Aplica un cross-encoder sobre el recall híbrido (BM25+vector). OFF por defecto: el reranker real es una dependencia pesada (torch).
rag.reranker_enabled

☐ Desactivado

Guardar

Mantenimiento

Palancas de los jobs programados.

Rotación de credenciales

Job periódico que rota secretos/leases en Vault.
cred_rotation_enabled

☒ Activado

Guardar

Escalado de tareas humanas

Sweep que reasigna/bloquea tareas humanas vencidas por timeout.
human_escalation_enabled

☒ Activado

Guardar

Figura 09.5 — Valores por defecto de plataforma

AGENTIC PLATFORM

Administración del Sistema

pág. 9 / 13

6 Programación de backups

Configura el **backup diario** del stack. La lectura está abierta a cualquier miembro autenticado (que ve una vista de solo lectura con los valores actuales); la edición es solo System Admin. Los cambios surten efecto en la siguiente ejecución sin reiniciar nada.

El formulario tiene tres campos: la casilla «**Backup diario activado**»; el campo «**Cron**» (cinco campos: minuto, hora, día del mes, mes y día de la semana; por defecto `0 3 * * *`, las 03:00 cada día); y «**Retención local (días)**», entre 1 y 3650, que indica cuánto se conservan los bundles antes de eliminarse tras un backup correcto. El botón «**Guardar**» se habilita solo cuando hay cambios y los valores son válidos; un cron inválido o una retención fuera de rango devuelve un error con el detalle.

The screenshot shows the 'Programación de backups' configuration page in the Agentic Platform. The interface is dark-themed. On the left is a sidebar with navigation items: 'TRABAJO', 'RECURSOS', 'CONFIGURACIÓN DEL TENANT', 'PLATAFORMA' (expanded), 'Usuarios', 'Proveedores LLM', 'Ollama & Embeddings', 'Valores por defecto', 'Modelos & Precios', 'Auth/SSO', 'Backups' (selected), 'Destinos backup', 'Restaurar backup', and 'AYUDA'. The top right of the header shows 'Demo Manuales', 'SYSTEM_ADMIN', 'ES', 'EN', and a user profile 'Demo Manuales Admin'. The main content area has a title 'Programación de backups' with a subtitle 'Cadencia (cron), ventana horaria y retención local del backup diario. Lectura abierta; edición solo System Admin.' Below this is a 'Configuración' box containing: a checked checkbox 'Backup diario activado', a 'Cron (ventana horaria)' field with the value '0 3 * * *', and a 'Retención local (días)' field with the value '7'. A 'Guardar' button is located at the bottom right of the configuration box.

Figura 09.6 — Programación de backups

7 Destinos remotos de backup

Gestiona los **destinos remotos** a los que se sube cada backup correcto y verificado: S3 (o compatible), Backblaze B2, SFTP/NAS y rclone. La edición es solo System Admin; un miembro normal ve una lista de solo lectura.

Cada destino es una tarjeta con su **tipo**, un **nombre**, la casilla «**Habilitado**» y los campos de configuración propios del tipo (bucket, prefijo, endpoint, región, host, usuario, ruta remota, remote, path...). **Importante:** las credenciales (claves de acceso, contraseñas, claves privadas, blob de rclone) nunca se introducen ni se muestran aquí; se resuelven desde el secret seam de los workers (Vault/env) al subir o probar. Usa «**Añadir destino**» para crear uno nuevo, el icono de papelera para eliminarlo, «**Probar conexión**» para verificar la conectividad de un destino y «**Guardar**» para persistir la lista (los campos obligatorios marcados con * deben estar completos).




Figura 09.7 — Destinos remotos de backup

8 Restaurar desde backup

Restaura el stack completo o un único tenant desde un backup. Es una operación **larga y destructiva**: el backend la encola como job en segundo plano y la pantalla sondea su progreso. Exclusiva del System Admin.

El flujo es: **1)** selecciona un backup de la lista «**Backups disponibles**» (muestra id, si está cifrado, tamaño y ubicaciones local/remotas). **2)** revisa el **Preview** con el manifest, los artefactos y si admite restauración por tenant. **3)** elige el **tipo de restore**: completo (detiene el stack y restaura todo) o selectivo por tenant (indicando el Tenant ID UUID; muestra las tablas afectadas). **4)** pulsa «**Restaurar...**» para abrir el diálogo de **doble confirmación**, donde debes teclear exactamente el token indicado (el id del bundle para un restore completo, o @ para uno por tenant); el backend re-deriva y valida ese token. **5)** una vez encolado, la tarjeta «**Progreso del restore**» muestra el estado del job hasta completarse (SUCCESS) o fallar (FAILURE) con el detalle.




Figura 09.8 — Restaurar desde backup

9 Estadísticas del tenant

Dashboard de rendimiento y consumo del tenant. A diferencia del resto del manual, esta pantalla requiere rol **tenant_admin** (no System Admin) y muestra únicamente datos del tenant activo; la comparativa entre tenants es una superficie aparte. Los costes están en USD canónico, con un selector de moneda solo para visualización (USD/EUR/GBP).

- **Selectores** de ventana temporal (30/90/365 días) y de moneda de visualización.
- **Tarjetas de cabecera:** tasa de éxito, número de runs, tiempo medio y coste medio, más una gráfica de tendencia de la tasa de éxito diaria.
- **Resumen de consumo:** coste total, runs, tokens (input/output/cached), la segmentación de coste IA vs humano y el run más costoso.
- **Agentes top y bottom** por tasa de éxito y una tabla de desglose por agente.
- **Explorador de runs:** tabla paginada y filtrable (por rol, verdict, modelo y coste mínimo) con una fila por ejecución (timestamp, plan, tarea, agente, rol, modelo, duración, tokens, coste, verdict y reintentos).




Figura 09.9 — Estadísticas del tenant